

Detecção automática do aquecimento em componentes de um sistema industrial, baseada no reconhecimento de imagens térmicas.

Oswaldo Flório Filho (UNINOVE) oswaldo@uninove.br
Sidnei Alves de Araújo (UNINOVE/USP) saraujo@uninove.br
Alice Flora Madeira Ribeiro Flório (UNINOVE) flora@uninove.br

Resumo

A necessidade de economia de energia e de ampliação da durabilidade dos componentes de um sistema industrial têm motivado o estudo de processos automáticos de controle que avaliam o desgaste destes componentes. Neste trabalho, explorou-se um método de reconhecimento de padrões de criticidade de elevação de temperatura em componentes, por uma rede neural artificial supervisionada, a partir de imagens térmicas codificadas pelo padrão de cores RGB. Além disso, analisou-se a sensibilidade da rede neural no processo de reconhecimento das imagens, em decorrência do nível de suavização na transição de cores das mesmas, usando diferentes paletas de cores. Esta análise possibilitou aumentar a eficiência do método proposto.

Palavras-chave: Imagens Térmicas, Redes Neurais, Processamento de Imagens.

1. Introdução

Devido à crescente automatização dos processos produtivos, têm sido desenvolvidas muitas técnicas de processamento de imagens digitais objetivando a solução de problemas relacionados à visão computacional. O propósito é fazer com que as máquinas tenham percepção visual, ou seja, possam “visualizar” uma imagem, extrair características intrínsecas da mesma, fazer um rápido processamento e interpretar o seu conteúdo semântico. Neste contexto, histograma e textura constituem as principais características para classificar e reconhecer imagens digitais, pois podem fornecer descrições das imagens e também medidas de similaridade entre elas. No processo de reconhecimento de imagens geralmente são empregadas técnicas de inteligência artificial (IA) tais como lógica fuzzy, algoritmos genéticos (AG's) e redes neurais artificiais (RNA's).

A termografia é uma técnica de análise térmica de um corpo, ou sistema, sem que haja contato físico com ele. Essa técnica se baseia na propriedade de que qualquer corpo com temperatura acima de 0°K emite uma radiação eletromagnética na faixa do infravermelho. Nesta faixa a radiação é imperceptível ao olho humano, mas pode ser sentida na forma de calor. Atualmente existem câmeras térmicas que permitem que o homem enxergue a radiação infravermelha. O princípio básico destas câmeras está na conversão da intensidade de radiação infravermelha em uma imagem padrão TV/vídeo. William Herschel (PASQUINI, 2003) comprovou que cada cor irradiada da luz solar branca tem influência específica no aumento da temperatura da superfície exposta. Algum tempo depois, Josef Stefan estabeleceu uma fórmula que exprime a relação entre a energia da radiação e a temperatura. Dessa forma, é possível interpretar as condições momentâneas de temperatura de cada parte de um objeto, por meio da grade de cores que se forma numa imagem tirada por uma câmera infravermelha. As imagens extraídas são chamadas de termogramas e estes revelam quantitativamente e com precisão, a existência de solicitações críticas de uma carga num corpo qualquer. O processo de medição por

termografia permite a obtenção de dados em vários campos do conhecimento. **Eles propiciam a análise preventiva para sistemas eletromecânicos e a detecção de tumores, de processos inflamatórios e de infecções no corpo humano** (BRIOSCHI, 2000). Além disso, de acordo com Pacheco (1998) é grande a utilização de imagens térmicas em pesquisas que implicam no mapeamento térmico da superfície da terra, na **análise de propriedades de rochas, solos e vegetações**.

Por outro lado, no que diz respeito ao uso das técnicas de IA para interpretação de imagens, encontram-se inúmeros trabalhos na literatura recente, os quais propõem diferentes métodos de classificação e reconhecimento de imagens digitais. Apesar disso, poucos têm sido os trabalhos publicados que exploram aplicações envolvendo imagens térmicas no campo industrial. Shiba et al (2005) propuseram um método baseado em árvores de decisão para classificação de imagens de sensoriamento remoto, descritas pelas três bandas do sistema de cores RGB.

Um método baseado em uma rede neural do tipo MLP (Multi Layer Perceptrons) para reconhecimento e recuperação de imagens descritas por atributos de cores foi proposto por Bender & Osório (2003). Alves & Araújo (2005) apresentaram um método para classificação de imagens de tecidos biológicos usando dois diferentes modelos de RNA's. No método proposto, as imagens foram caracterizadas por histogramas e por descritores estatísticos de segunda ordem.

Neste estudo investigou-se a possibilidade da identificação de um padrão de criticidade de um componente, pertencente a um corpo ou sistema, com relação a sua temperatura, partindo-se de uma imagem térmica do mesmo. Além disso, fez-se uma análise sobre a influência da suavização na transição de cores da imagem no processo de reconhecimento dos padrões de criticidade pela rede neural. Para isto, foram utilizadas duas diferentes paletas de cores denominadas "Feather" e "Own Pal2". **A partir deste trabalho, pretende-se investigar a viabilidade de desenvolvimento de um sistema de controle para aumentar a vida útil dos componentes e possibilitar a redução do consumo de energia.**

2. Imagens Digitais

Uma imagem digital pode ser representada como uma função bidimensional de intensidade de luz $f(x, y)$ com $x, y \in Z^2$, onde x e y determinam a localização espacial e f a intensidade brilho. Também pode ser entendida como uma matriz na qual cada elemento dessa matriz, denominado *pixel*, identifica um ponto na imagem e o valor do elemento identifica o nível de cinza naquele ponto (GONZALEZ, 2002; CASTLEMAN, 1996; PRATT 1991). Uma imagem em níveis de cinza G^y (equação 1) é uma função cujo contra-domínio representa diferentes níveis de cinza no intervalo real $[0, 1]$. Este intervalo geralmente é discretizado para o intervalo inteiro $[0, 255]$, onde o valor 0 é associado ao preto e o valor 255 correspondente ao branco (ARAUJO, 2005). Os valores intermediários, naturalmente, representam os diversos de tons de cinza entre 0 e 255. Uma imagem colorida C^y (equação 2), é uma imagem multibanda, onde a cor de cada *pixel* pode ser representada de acordo com um modelo de cor. Os modelos de cores comumente utilizados em processamento de imagens digitais são o RGB (*Red, Green, Blue*), que é abordado neste trabalho, e o HSI (*Hue, Saturation, Intensity*). No modelo de cor RGB, uma imagem colorida pode ser vista como um conjunto de três imagens em níveis de cinza independentes (G_r^y, G_g^y e G_b^y), cada uma delas representando uma das

componentes de cor (vermelho, verde e azul). No modelo HSI, as três imagens em níveis de cinza representam a matiz (*Hue*), a saturação (*Saturation*) e a intensidade (*Intensity*). A matiz está relacionada à cor do pixel, a saturação e a intensidade estão relacionadas, respectivamente, com a pureza da cor e com a quantidade de luz (brilho).

$$G^y : Z^2 \rightarrow [0, 255] \quad (1)$$

$$C^y \Rightarrow G_{r,g,b}^y : Z^2 \rightarrow [0, 255] \quad (2)$$

2.1 Imagens Térmicas

Existem duas formas de medição de temperatura: a **Termometria** e a **Termografia**. A **termometria se baseia na transmissão do calor pela condução. A termografia parte do princípio da transmissão de calor por radiação. Enquanto a termometria exige o contato do instrumento medidor com a área focada, a termografia permite registrar a temperatura dessa área sem o contato com a mesma.**

Todos os corpos, que estejam com temperaturas superiores ao zero absoluto (0°K), emitem radiações eletromagnéticas na faixa de frequência do infravermelho. Estas radiações emitidas pela superfície de um corpo contêm informações que determinam as características da matéria que o compõem, bem como as suas propriedades. A visão humana responde ao espectro de cores que vai do vermelho ao violeta e compreende o comprimento de onda na faixa de 400 a 700 micrômetros. Já o comprimento de onda do infravermelho corresponde à faixa de 0,7 a 1000 micrômetros, o que o torna, portanto, não detectável pelo olho humano. Entretanto, uma das características do infravermelho é a sua propriedade térmica.

Uma câmera térmica, ao contrário das câmeras comuns, procura identificar esta característica e transformá-la em uma imagem visível para o homem. Esta técnica é chamada de termografia e as imagens obtidas são nomeadas termogramas. Os termogramas permitem a obtenção de medidas precisas de temperatura, a distinção da distribuição de calor emitido pela região focalizada e a identificação das curvas isotérmicas do corpo em análise. Dessa forma, por meio de um sistema de aquisição e tratamento apropriado, podem-se obter informações que proporcionem o conhecimento e posterior controle dos parâmetros desse elemento.

A medicina, a astronomia, a veterinária, a geodésica, a área industrial, entre outras, utilizam as imagens térmicas com objetivos específicos. Em particular, **a área industrial tem se beneficiado da termografia para a detecção antecipada de falhas em sistemas elétricos ou mecânicos, reduzindo, assim, o custo de reparação.**

3. Redes Neurais Artificiais

As redes neurais artificiais (RNA's), ou simplesmente "redes neurais", consistem de uma técnica de inteligência artificial e têm como inspiração a estrutura e o funcionamento do cérebro humano (HAYKIN, 1999; MITCHELL, 1997). Atualmente as redes neurais têm sido amplamente utilizadas, visto que essa técnica tem apresentado resultados interessantes na resolução de problemas referentes à classificação e/ou reconhecimento de padrões nas diversas áreas do conhecimento tais como engenharia, medicina, química, biologia, física, entre outras. Assim como o cérebro humano, uma rede neural artificial é composta de elementos interligados, denominados neurônios artificiais, e suas principais atribuições são: processar, filtrar e disparar o sinal recebido.

A combinação de diversos neurônios artificiais forma uma malha denominada rede neural artificial na qual as entradas simulam os dendritos do neurônio biológico e fazem a captação de estímulos. As conexões entre os neurônios artificiais, em comparação com o sistema biológico, representam as sinapses e são simuladas pelos vetores de pesos. O aprendizado de uma RNA é feito através de um processo iterativo de ajustes aplicados a seus pesos e pode ocorrer de dois diferentes modos: supervisionado ou não-supervisionado. No modo supervisionado faz-se necessário o auxílio de um “professor”. Isso é caracterizado pela existência de um conjunto de entradas com as respectivas saídas desejadas. No aprendizado não-supervisionado, é desnecessária a existência de um “professor”, ou seja, não se requer saídas desejadas para o conjunto de treinamento. Dadas as suas características, este último modo de aprendizagem é citado por alguns autores como “biologicamente plausível” (HAYKIN, 1999).

O Multi Layer Perceptron (MLP), utilizado neste trabalho, é um modelo de rede neural de aprendizado supervisionado e amplamente conhecido como Perceptron de Múltiplas Camadas. Caracteriza-se por possuir, além da camada de entrada e camada de saída, uma ou mais camadas ocultas. Estas camadas permitem que a rede mapeie padrões de entrada com estruturas similares, para saídas diferentes, como é o caso da função ou-exclusivo (XOR) (RUSSEL, 1995; RICH, 1994). Para o treinamento do MLP, geralmente utiliza-se o algoritmo backpropagation (HAYKIN, 1999; RICH, 1994; ARAUJO, 2005) que é baseado em aprendizagem por correção de erro, no qual o treinamento é composto por duas fases: propagação e retropropagação. Na primeira fase (propagação), quando um padrão é apresentado à rede através da camada de entrada, o sinal de ativação é propagado camada por camada, até que a resposta seja produzida pela camada de saída. Na segunda fase (reteropropagação), a saída da rede é comparada com a saída desejada para aquele padrão particular. Produz-se, então, um sinal de erro que é propagado a partir da camada de saída até a camada de entrada, promovendo o ajuste dos pesos sinápticos para que a resposta da rede se aproxime da resposta desejada (HAYKIN, 1994; RUSSEL, 1995).

4. Materiais e Métodos

O método proposto neste trabalho (Figura 1) é composto de 5 etapas: aquisição da imagem térmica, segmentação da região de interesse da imagem térmica, extração da imagem G_r^y a partir da região segmentada, obtenção da descrição do padrão da imagem, dada pelo histograma de G_r^y e a classificação do padrão pela rede neural.

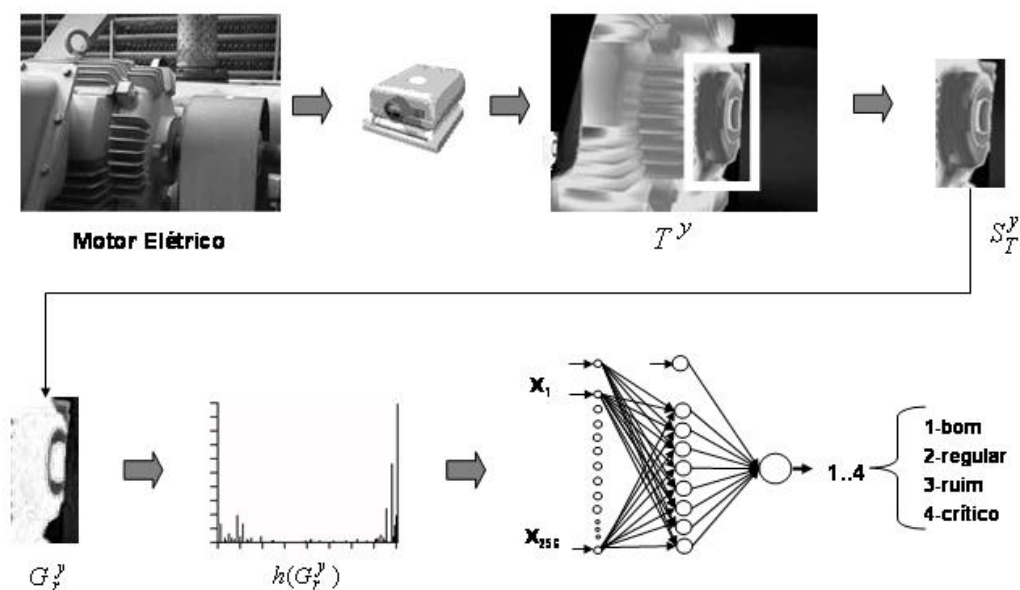


Figura 1 – Etapas de funcionamento do sistema proposto

Na primeira etapa, a imagem do corpo ou sistema é adquirida por uma câmera térmica e armazenada segundo o padrão de uma paleta de cores selecionada. Para averiguar se o reconhecimento da imagem, pela rede neural, é afetado pelo nível de suavização na transição de cores da imagem, utilizamos duas diferentes paletas: “Feather” e “Own Pal2”. A primeira paleta apresenta um gradiente de cores que varia, de forma suave, do azul (temperatura mínima) ao branco (temperatura máxima), passando por cores intermediárias como verde, amarelo, laranja e vermelho. A segunda paleta apresenta o mesmo gradiente de cores, com a diferença de que a mudança de uma cor para outra é feita de forma brusca.

Denotamos imagem térmica adquirida por T^y . A segmentação da imagem T^y para extração das regiões de interesse (componentes) é feita em pontos pré-determinados dado que estas regiões são definidas de acordo com o componente que está sendo observado. A partir da imagem gerada no processo de segmentação (sub-imagem de T^y), denotada por S_T^y , gera-se a imagem G_r^y , por meio de uma etapa de processamento no qual são extraídas as três imagens em níveis de cinzas G_r^y, G_g^y e G_b^y . O histograma da imagem G_r^y , denotado por $h(G_r^y)$, é então obtido para descrever um padrão de imagem. Estes histogramas são utilizados como entrada para a rede neural tanto na fase de treinamento quanto na fase de reconhecimento dos padrões. A última etapa do método é a classificação do padrão de imagem pela rede neural. **Definimos que uma imagem pode pertencer a uma de quatro classes distintas numeradas de 1 a 4, de acordo com o padrão de aquecimento observado no componente. Para caracterização das classes usamos as seguintes denominações: 1-bom, 2-regular, 3-ruim e 4-crítico. O padrão bom define que a temperatura do componente está dentro dos valores de regime de operação. A denominação regular mostra a elevação da temperatura a um nível ainda aceitável de trabalho do componente. Por sua vez, a denominação ruim identifica a elevação da temperatura acima do nível aceitável sem dano irreversível do componente, porém com comprometimento de sua vida útil. Já a denominação crítico indica alta probabilidade da ocorrência de danos permanentes no componente em questão.**

4.1 Processamento de Imagens

Para todos os procedimentos descritos nas etapas do método proposto utilizamos a linguagem C. Para as etapas que envolvem o processamento das imagens, utilizamos também uma biblioteca denominada IMG que consiste de um conjunto de classes, rotinas e operadores “sobrecarregados” para processamento de imagens escrito em C++, desenvolvida por (KIM, 2006). Nesta seção, apresentamos com mais detalhes as etapas de segmentação da região de interesse da imagem T^y , extração da imagem G_r^y da região segmentada e a obtenção do histograma de G_r^y .

- Segmentação da região de interesse da imagem: Conforme já mencionado, a segmentação da região de interesse é dada de acordo com o objeto que está sendo observado. Assim, para extração de S_T^y são fornecidos apenas dois pares de coordenadas (x_1, y_1, x_2, y_2) .
- Extração de G_r^y a partir da região segmentada (S_T^y): Como as imagens T^y são armazenadas utilizando-se 24 bits por pixel, cada componente de cor é representada por 8 bits de acordo com a definição dada na equação 2.
- Obtenção de $h(G_r^y)$: É dado pela equação 3 a seguir:

$$h_k[G_r^y] = \frac{n_k}{n} \quad \forall k \in [0, 255]$$

k = nível de cinza
 n_k = quantidade de pixels com o nível de cinza k na imagem G_r^y
 n = quantidade de pixels da imagem G_r^y

(3)

4.2 Aprendizagem dos padrões de imagem pela rede neural artificial

A classificação das imagens pela aprendizagem da rede neural artificial envolveu quatro conjuntos de padrões de imagens: dois para o treinamento da rede denotados por $P1 = \{p1_1, p1_2, \dots, p1_n\}$ e $P2 = \{p2_1, p2_2, \dots, p2_n\}$, e outros dois para fase de testes que denotamos por $Q1 = \{q1_1, q1_2, \dots, q1_n\}$ e $Q2 = \{q2_1, q2_2, \dots, q2_n\}$. Os conjuntos $P1$ e $Q1$ foram compostos, respectivamente, por 80 e 60 imagens amostras de objetos, com características de funcionamento e padrões de aquecimento diferentes, utilizando-se a paleta “Feather” onde o gradiente de cores varia suavemente enquanto os conjuntos $P2$ e $Q2$, com as mesmas quantidades de padrões, foram compostos por imagens utilizando a paleta “Own Pal2” na qual o gradiente de cores varia de forma brusca. Em todos os conjuntos, as quantidades de imagens por classe são iguais.

Para elaboração dos conjuntos (treinamento e testes) utilizou-se os histogramas $h(G_r^y)$ de imagens amostras G_r^y . Dessa forma, cada $p1_i \in P1$, $p2_i \in P2$, $q1_i \in Q1$ e $q2_i \in Q2$, é um vetor de 256 elementos que representam a distribuição dos níveis de cinza de G_r^y . A idéia é realizar o treinamento da rede neural com os conjuntos $P1$ e $P2$, e verificar os resultados da classificação das imagens dos conjuntos $Q1$ e $Q2$, com o intuito de constatar qual das duas paletas de cores oferece melhores condições para ser utilizada como parâmetro pelo método.

4.3 Características da rede neural artificial

Para o treinamento e classificação das imagens **utilizou-se uma rede neural Multi Layer Perceptron treinada com o algoritmo backpropagation**. A camada de entrada da rede possui 257 neurônios, sendo 256 provenientes de $h(G_r^y)$ e 1 para o bias. Utilizou-se uma única camada oculta com 30 neurônios e apenas um neurônio na camada de saída. A função logística $1/(1+e^{-\alpha x})$ foi utilizada como função de ativação para todas as camadas. A arquitetura da RNA proposta é ilustrada na Figura 2.




Figura 2 – Arquitetura da RNA utilizada para classificação das imagens

5. Resultados Experimentais

Os experimentos foram realizados da seguinte maneira: primeiro foi feito o treinamento da rede com o conjunto $P1$ e, em seguida, a rede foi testada com o conjunto $Q1$. Na fase seguinte, treinou-se a rede com o conjunto $P2$ e verificou-se os resultados da classificação das imagens do conjunto $Q2$. O tempo médio de treinamento da rede neural com os parâmetros descritos na seção anterior, usando um microcomputador Pentium-4 2.8 GHz foi de aproximadamente 3 minutos. Para realização das etapas de processamento e classificação de uma imagem de uma região de interesse com 100 x 50 pixels o tempo médio foi de aproximadamente 0.05 segundos. Os resultados dos testes realizados com os conjuntos $Q1$ e $Q2$ são apresentados, respectivamente, nas Tabelas 1 e 2 a seguir.

Classe	Padrão de Aquecimento	Qtd. Padrões	Acertos	Erros	% Acerto
1	Bom	15	15	0	100,0
2	Regular	15	13	2	86,7
3	Ruim	15	14	1	93,3
4	Crítico	15	14	1	93,3
Totais	-	60	56	04	93,3

Tabela 1. Resultados da fase de testes para o conjunto $Q1$.

Os dados apresentados na Tabela 1 mostram claramente que o desempenho da rede neural na classificação das imagens foi satisfatório. Como podemos observar, a maior quantidade de erros aconteceu na classe 2 (padrão de aquecimento regular). Isso pode ter sido causado pelo fato das imagens com este padrão de aquecimento, representado pela cor verde, conter, com

frequência, muitos pixels com cores que representam outros padrões de aquecimento, como o azul que representa o padrão 1-bom e o laranja que representa o padrão 3-ruim.

Classe	Padrão de Aquecimento	Qtd. Padrões	Acertos	Erros	% Acerto
1	Bom	15	15	0	100,0
2	Regular	15	14	1	93,3
3	Ruim	15	14	1	93,3
4	Crítico	15	14	1	93,3
Totais	-	60	57	03	95,0

Tabela 2. Resultados da fase de testes para o conjunto Q2

Para o conjunto Q2, como podemos observar nos dados apresentados na Tabela 2, os resultados foram, no geral, melhores que aqueles apresentados para o conjunto Q1 (Tabela 1). Outro fator interessante é que o treinamento com o conjunto P2, na maioria das simulações realizadas, foi mais rápido do que o treinamento com o conjunto P1. Isso mostra que a rede “aprendeu” com mais facilidade os padrões utilizando um gradiente de cores com uma variação brusca. Uma possível explicação para este fato é que quando a transição de cores na imagem ocorre de forma suave, para dar o efeito de “suavidade” há uma mistura de cores naquela região. Isto acarretará o aumento das tonalidades dos níveis de cinzas na imagem, o que impõe um maior grau de dificuldade no aprendizado da rede neural.

6. Conclusão

Neste trabalho, explorou-se um método de detecção automática de aquecimento em componentes de um sistema industrial por meio de imagens térmicas dos mesmos. Para reconhecimento dos padrões de aquecimento nas imagens, utilizou-se uma rede neural artificial treinada com o algoritmo Backpropagation. Investigou-se também a influência da suavização na transição de cores da imagem no reconhecimento dos padrões de aquecimento pela rede neural. Os experimentos realizados mostraram que o método usando a abordagem neural obteve resultados expressivos e mostrou-se robusto e rápido podendo ser usado na prática para aplicações em tempo real. Com relação à investigação da influência da suavização na transição das cores na imagem, foi constatado que as variações bruscas de cores facilitam o aprendizado da rede neural tornando os resultados da classificação mais expressivos.

Com base nos resultados apresentados neste trabalho, pretende-se, em estudos futuros, investigar a possibilidade de desenvolvimento de um sistema de controle automático que proporcione o aumento da vida útil dos elementos industriais com a conseqüente redução do consumo de energia.

Referências

ALVES, W. A. L. & ARAÚJO, S. A. *Uma Avaliação da Utilização de Dois Diferentes Modelos de Redes Neurais na Classificação de Imagens Baseada em Características Texturais*. Anais do XVIII Brazilian Symposium on Computer Graphics and Image Processing - SIBGRAPI 2005, Natal-RN, 2005.

ARAÚJO, S. A. & KIM, H. Y. *Meio-Tom Inverso Usando Redes Neurais Artificiais*. In: Anais do XXII Simpósio Brasileiro de Telecomunicações (SBrT'05), Campinas-SP, Vol. 1. p.226-231, 2005.

BAHTEN, L. C. Von . *Teletermografia Médica: Diagnóstico por imagem térmica infravermelha digital*. Arquivos de Medicina, Curitiba-PR: Vol. 1, n.1, p.33-40, 2000.

BENDER, T. C. & OSÓRIO, F. S. *Reconhecimento e recuperação de imagens utilizando redes neurais artificiais. do tipo MLP*. Anais do IV Encontro Nacional de Inteligência Artificial, Campinas-SP, 2003.

BRIOSCHI, M. L. ; COLMAN, D.; NAKAGAWA, C. R. ; CIMALISTA JR, M. CASTLEMAN K. R. *Digital Image Processing*. Prentice-Hall, New Jersey, 1996.

GONZALEZ, R. C. & WOODS, R. E., *Digital Image Processing*. 2.nd., Prentice Hall, New Jersey, 2002.

HAYKIN, S. *Neural Networks – A Comprehensive Foundation*. 2.nd., Prentice Hall, New Jersey, 1999.

KIM, H.Y. *Sistema – IMG*. LPS/POLI/USP. <<http://www.lps.usp.br/~hae/software/>>. Acesso em 11/03/2006.

MITCHELL, T. *Machine Learning*. McGraw Hill, 1997.

PACHÊCO, A. P. *Emissividades de Superfícies Naturais no Infravermelho Termal*. Anais do IX Simpósio Brasileiro de Sensoriamento Remoto, Santos-SP, p.1307-1313, 1998.

PASQUINI, C. *Near Infrared Spectroscopy: fundamentals, practical aspects and analytical applications*, Journal of the Brazilian Chemical Society, Vol.14, n.2, p.198-219, 2003.

PRATT, W. K. *Digital image processing*. John Wiley, New York, 1991.

RICH, E., *Inteligência artificial*. Makron Books, São Paulo, 1994.

RUSSEL, S. & NORVIG, P. *Artificial intelligence a modern approach*. Prentice Hall, New Jersey, 1995.

SHIBA, M. H.; SANTOS, L. R.; QUINTANILHA, J. A.; KIM, H. Y. *Classificação de imagens de sensoriamento remoto pela aprendizagem por árvore de decisão: uma avaliação de desempenho*. Anais do XII Simpósio Brasileiro de Sensoriamento Remoto, Goiânia-GO, p.4319-4326, 2005.